




**BURSA TEKNİK
ÜNİVERSİTESİ**

Süreç Madenciliği Günlüklerinde MLP ve LSTM/GRU Tabanlı Anomali Tespiti

BLM0463 Veri Madenciliğine Giriş — Dönem Projesi

Sunan: Büşra Uzunlar · 20360859098



Problem Tanımı ve Proje Amacı

Mevcut Durum

Sistem loglarındaki olağan dışı kullanıcı davranışlarının tespiti, yalnızca komut sayısına dayalı basit etiketleme yöntemleriyle yapılmaktadır. Komut parametreleri ve semantik içerik göz ardı edilmektedir.

Projenin Hedefleri

- Çok değişkenli ve semantik özellik analizi gerçekleştirmek
- Isolation Forest ve LOF ile bilimsel anomali etiketleri üretmek
- MLP, LSTM ve GRU modellerini eğiterek performanslarını karşılaştırmak

Veri Seti Yapısı ve Ön İşleme

	A	Adatane Cleaning	Hebomjin04	E	U	E	G	E	D
1	✖	✖	✖	✖	✖	✖	✖	✖	✖
2	2	Nadrano	DRal MA	AL	1	K	CAIS		
2	4	Data Cleaning	ProColData	IRAWSTUSI	HC/K	RLave	CWMe	Secto8	S ₂ NCK
2	4	DATH Stt2 OHB,21%	9%	390	\$90	\$5,077	\$37,887	\$08	\$4,1304
3	3	DAVR (026/ H6,48%)	\$4,506	86	380	\$15	\$1,5%	\$28,882	\$07
6	4	DATH (026/ H6,48%)	\$3,545	99	155	\$0%	\$6%	\$31,00%	\$57
6	5	DAVR (26/ H6,48%)	\$5,255	\$6	189	\$1%	\$9%	\$37,307	\$55
9	4	DAVR (26/ H6,48%)	\$8%	\$3	\$00	\$10	\$3%	\$15,500	\$63
8	6	CHVF (132/ H6,48%)	\$4,536	\$6	\$83	\$46	\$4%	\$77,500	\$38
7	9	DAVR (32/ H6,48%)	\$3,335	\$5	\$96	\$55	\$6%	\$27,300	\$00
18	9	CATH (28/ H6,48%)	\$5,555	\$66	\$33	\$42	\$00%	\$51,000	\$4%
12	9	DAVR (26/ H6,48%)	153	\$8	\$59	\$1.1	30%	\$471,500	\$5%
12	9	DNE (26/ H6,48%)	1106	87	\$01	\$86	\$20%	\$18,308	908
12	8	CAT (22/ H6,48%)	1306	\$0	\$09	\$57	\$60%	\$1206	257
18	99	DAL (26/ H6,48%)	1637	\$8	\$16%	\$25	\$30%	\$51,309	\$09
12	19	DAE (24/ H6,48%)	1868	\$8	\$1.8%	\$98	\$60%	\$51,308	\$16
16	114	DAT (29/ H6,48%)	1886	\$5	\$4.0%	\$73	\$60%	\$190%	\$00
12	115	CA (23/ H6,48%)	1886	\$5	\$4.0%	\$73	\$60%	\$190%	\$00
12	11	DAVR (26/ H6,48%)	39					\$559%	456
19	17	DIC (23/ H6,48%)							

Veri Kaynağı

Zenodo üzerindeki **data1** ve **data2** süreç madenciliği CSV dosyaları.

Ön İşleme Adımları

- cmd_arguments alanındaki eksik değerler 'none' ile dolduruldu
- username alanındaki eksikler 'unknown' olarak işaretlendi
- Zaman damgaları standart datetime tipine dönüştürüldü

11.745

Toplam log satırı

100

Benzer oturum (sandbox_id)

Özellik Mühendisliği ve NLP (TF-IDF)

İstatistiki & İleri Seviye Özellikler


- **Temel:** Komut sayısı, benzersiz komut türleri, IP/makine/kullanıcı sayıları, ortalama yetki seviyesi
- **Zamansal:** `session_duration`, `commands_per_minute`, `average_time_between_commands`
- **Güvenlik:** `command_entropy` (Shannon Entropisi), `ratio_of_privileged_commands` (Level ≥ 45)

Sematik Analiz: TF-IDF

Komut isimleri ve argümanları birleştirilerek metinsel özellikler çıkarıldı. En önemli **20 kelime** üzerinden TF-IDF vektörleri üretildi; bu sayede komutların anlamsal içeriği modele taşındı.

- ❗ TF-IDF, nadir ama ayırt edici komutlara daha yüksek ağırlık vererek anomali sinyallerini güçlendirir.

Anomali Etiketleme Stratejileri



Yöntemlerin Karşılaştırılması

Üç farklı strateji bağımsız olarak uygulanmış ve etiketleme kararları karşılaştırılmıştır.

Düşük örtüşme oranı, her yöntemin farklı anomali perspektifini yakaladığını göstermektedir.

IForest $\cap$ LOF

4 oturum ortak anomali kararı

IForest $\cap$ Persentil

3 oturum ortak anomali kararı

Model Mimarileri

MLP

Giriş (Özellikler + TF-IDF) →
Dense(64, ReLU) → BN →
Dropout(0.3) → Dense(32, ReLU) →
BN → Dropout(0.3) → Sigmoid

Çift Yönlü LSTM


Embedding (Komut dizileri) →
BiLSTM(64) → BN → Dropout →
Dense(32) → Sigmoid

Çift Yönlü GRU

Embedding → BiGRU(64) → BN →
Dropout → Dense(32) → Sigmoid

📋 **Eğitim Ayarları:** Adam optimizasyon algoritması, Binary Crossentropy kaybı, Stratified Train-Test Split (%80 eğitim / %20 test)

Deneyisel Sonuçlar ve Performans Metrikleri




Temel Bulgular

MLP + ROS tüm metriklerde mükemmel performans sergiledi: Acc: 1.00, F1: 1.00, AUC: 1.00

LSTM & GRU yüksek AUC değerlerine rağmen F1 = 0.00 elde etti; sınıf dengesizliği recall'ı sıfırladı.

SMOTE ile MLP'nin F1 skoru 0.50'den 0.67'ye yükseldi, AUC mükemmelliğe ulaştı.





Sonuç ve Öneriler

1

En Başarılı Model

NLP özellikli ve ROS ile dengelenmiş MLP modeli, canlı sistemler için en uygun çözüm olarak öne çıkmaktadır.

2

Süreç Madenciliği Önerisi

Sıralı modellerin (GRU/LSTM) tam potansiyeliyle çalışabilmesi için veri kümesindeki **oturum sayısı artırılmalıdır**.

3

Gelecek Çalışmalar

Karar eşiği optimizasyonu yapılması ve modellerin **gerçek zamanlı log akışı** üzerinde test edilmesi planlanmaktadır.



Dikkatiniz için Teşekkürler!